AskLake

B2B SaaS 데이터 통합·분석 플랫폼

염태선

황선호

박태정

이해건

이원재

유중일

서비스 소개

빅데이터를 위한 파이프라인
구축 및 운영은 여전히 어렵습니다

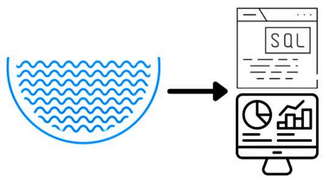

AskLake는 데이터 수집부터 소비까지,
하나의 흐름으로 쉽게 연결합니다.

다양한 형식의 대규모 분산 데이터를, 더 쉽고 신뢰할 수 있게 활용하려면 어떻게 해야 할까요?

오늘날 데이터는 S3와 같은 객체 스토리지, Kafka 기반의 실시간 스트림, 여러 운영 시스템과 서비스 곳곳에 흩어져 있습니다. 하지만 데이터를 연결하고, 구조를 이해하고, 분석 가능한 형태로 정제해 인사이트로 전환하기까지는 여전히 많은 시간과 전문성이 필요합니다.

AskLake는 이러한 과정을 하나의 흐름으로 연결하는 통합 데이터 레이크 플랫폼입니다. S3·Kafka 등 다양한 데이터 소스를 연결하고, 데이터 수집부터 정제, 카탈로그 관리, SQL 분석, 실시간 처리, 대시보드 시각화까지 필요한 기능을 한곳에서 제공합니다.

AskLake는 복잡한 데이터 인프라를 단순한 사용자 경험으로 바꿉니다. 데이터가 들어오는 순간부터 신뢰할 수 있는 정보가 되고, 다시 가치 있는 의사결정과 인사이트로 이어지는 순간까지. 누구나 쉽고 일관되게 데이터를 활용하도록 돕는 지능형 데이터 플랫폼입니다.

github에서 AskLake
의 코드를 확인해보세요
https://github.com/JUNGLE-TEAM1/AskLake

핵심 기능 요약

데이터 수집부터 소비까지 하나의 흐름으로

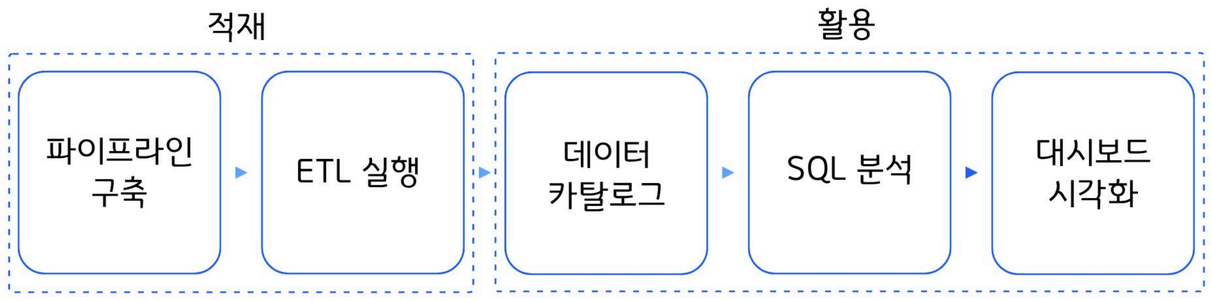

공통 기반	거버넌스	신뢰성	AI 어시스턴트
	정책 · 권한 · 리니지 · 품질	모니터링 · 백업 · 복구	

기술적 챌린지

#1 데이터 규모별 재사용 전략 자동 선택

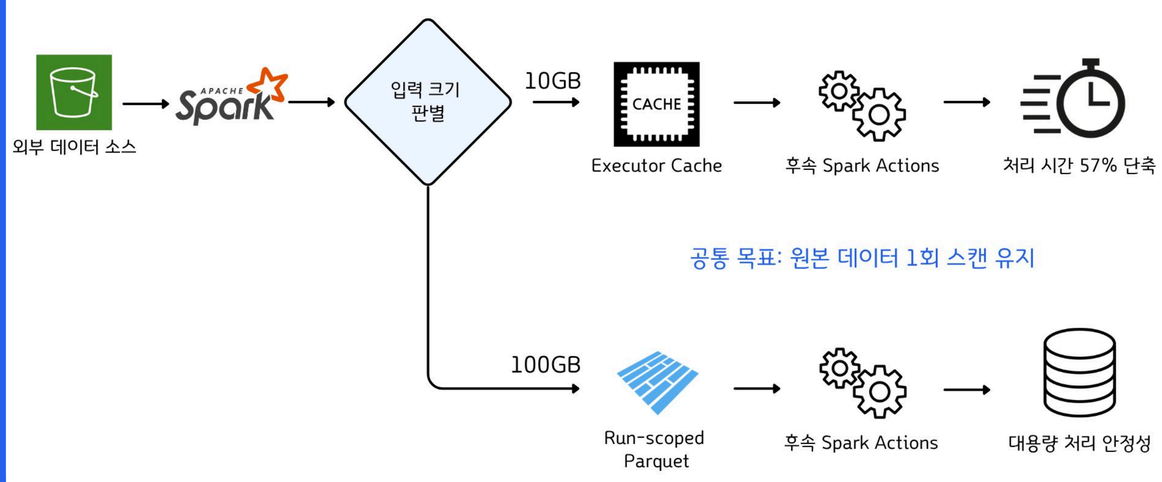

- 입력 규모에 따라 ETL 처리 과정에서 원본 데이터 재사용 방식을 자동 분기
- 두 방식 모두 원본을 1회만 스캔하여 효율적인 처리 시스템 개발
- 작은 규모의 데이터는 캐시를 이용해 처리 속도를 기존 방식 대비 57% 단축
- 큰 규모의 데이터는 Parquet로 임시 저장을 통해 외부화 과정을 진행, 대용량 데이터를 안정적으로 처리

#2 입력 규모·실행 이력 기반 Spark Resource Planner

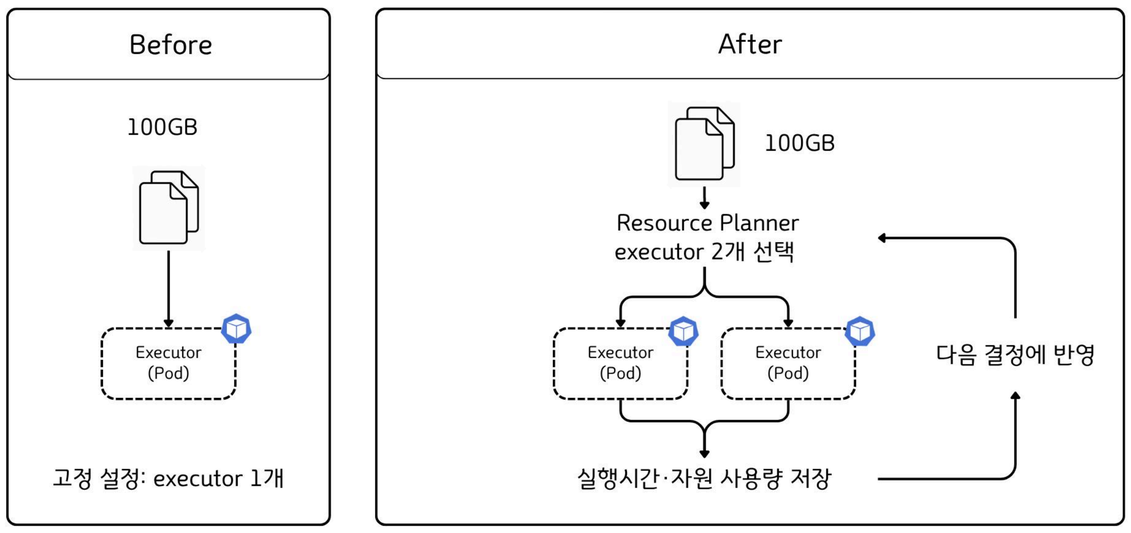

- 데이터 크기와 실행 이력을 비교해 적정 개수를 자동 선택
- 실행 결과를 다음 작업의 판단에 다시 반영

아키텍처

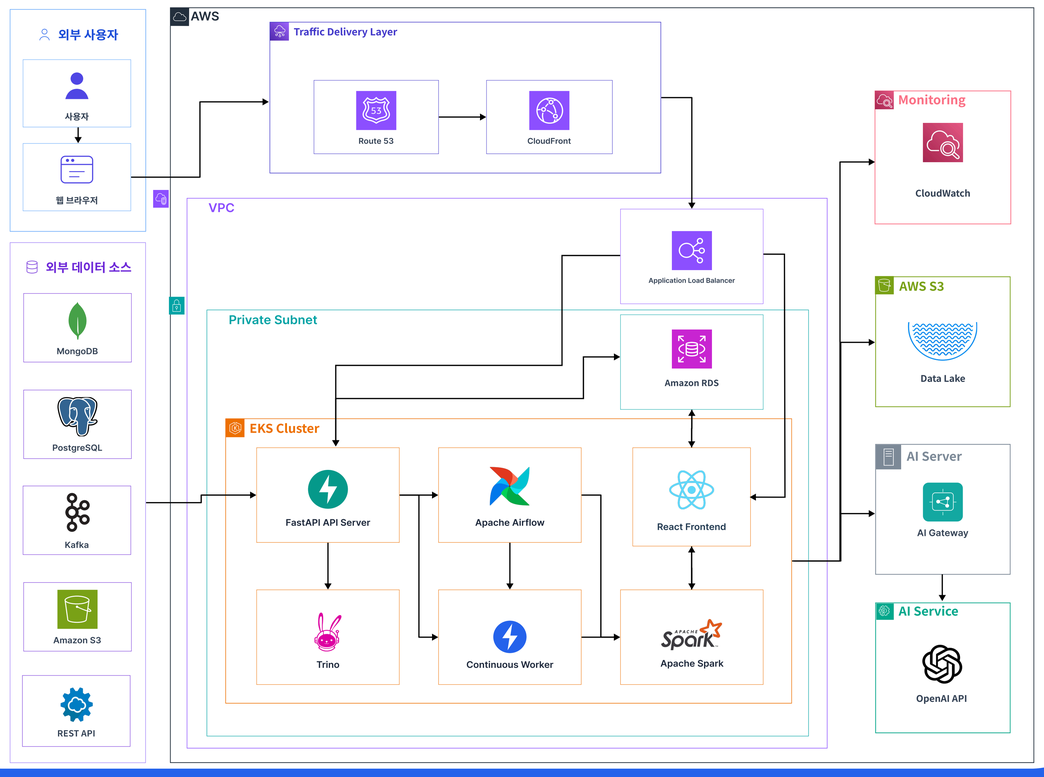

기능 설명

1 데이터 가공과 스케줄링

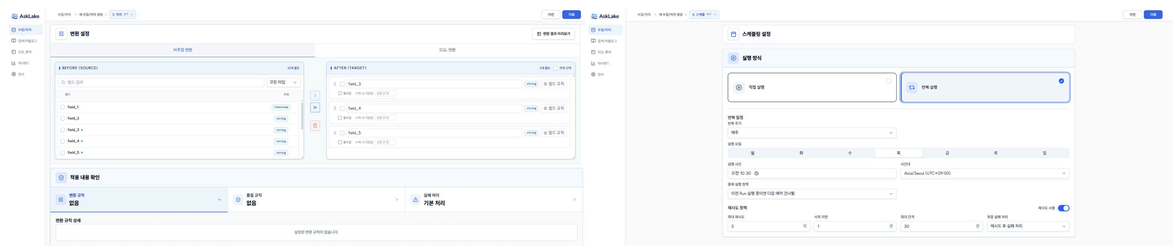

AskLake는 다양한 데이터 소스를 연결하고 수집부터 저장까지의 처리 과정을 단계별로 설계할 수 있는 환경을 제공합니다.
복잡한 코드를 직접 작성하지 않고도, 원본 데이터의 구조와 실행 조건을 확인하며 안정적인 데이터 파이프라인을 구성할 수 있습니다.
ETL 실행 주기 또한 원하는대로 쉽게 설정이 가능합니다.

2 데이터 파이프라인 실행 내역

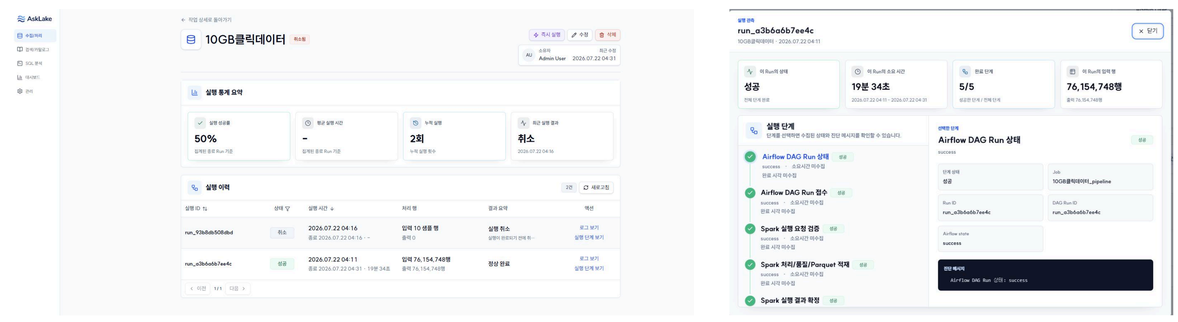

생성된 데이터 파이프라인의 실행 상태와 처리 결과를 작업별로 확인할 수 있습니다.
실행 시작부터 완료까지의 진행 상황과 단계별 결과가 기록되므로, 오류가 발생한 지점을 빠르게 찾고 필요한 작업을 다시 실행할 수 있습니다.

3 데이터 카탈로그와 리니지

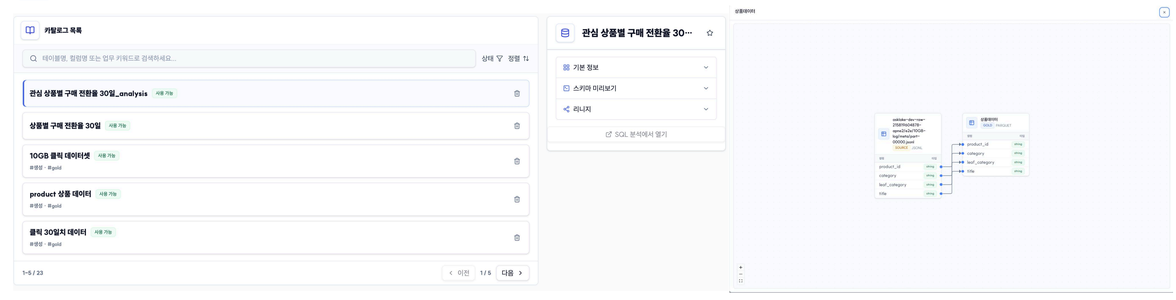

AskLake의 데이터 카탈로그는 데이터 레이크에 적재된 데이터셋을 한 곳에서 검색하고 이해할 수 있도록 정리합니다.
데이터가 어디에서 생성되고 어떤 처리 과정을 거쳤는지 리니지를 통해 시각적으로 확인할 수 있어, 데이터의 신뢰성과 활용도를 높입니다.

4 SQL 분석

카탈로그에서 발견한 데이터셋을 즉시 SQL 분석 화면으로 연결할 수 있습니다. 여러 데이터의 구조를 확인하면서 쿼리를 작성하고, 실행 결과를 미리 검증한 뒤 새로운 처리 작업이나 대시보드로 확장할 수 있습니다.

5 대시보드 시각화

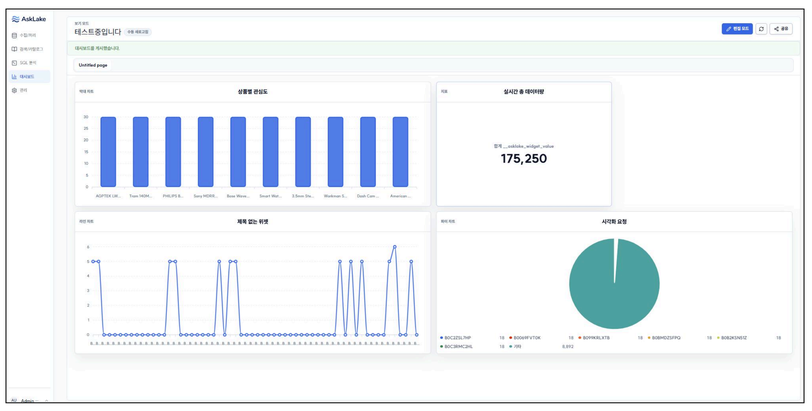

데이터셋을 다양한 차트와 지표로 구성해 위젯을 생성하고, 대시보드를 생성할 수 있습니다.
실시간으로 변화하는 데이터 또한 시각적으로 확인이 가능합니다.